

Exercício Programa: Inferência Estatística e Machine Learning em TI

Aplicação Prática: Análise de Confiabilidade de Servidores em Nuvem

Disciplina: Inferência Estatística

Professor: Msc. Kyung Moo Kim

Carater caráter: Trabalho Individual

Data Limite de Entrega: 15 de Setembro

Forma de Entrega: Submissão via link do Google Colab (código executável e comentado)

1. Contextualização e Diretrizes Gerais

No cenário atual de engenharia de confiabilidade de sites (SRE) e infraestrutura em nuvem, a monitoração proativa de servidores é vital para evitar interrupções de serviços críticos. O objetivo deste Exercício Programa (EP) é aplicar rigores metodológicos da **Inferência Estatística** (estimadores, intervalos de confiança e testes de hipóteses) combinados com técnicas de aprendizado de máquina e redução de dimensionalidade (**PCA** e **KNN**) em um conjunto real de dados fornecido (`servidores_ti.csv`).

Atenção: Este trabalho é **estritamente individual**. A entrega deve ser realizada obrigatoriamente até o dia **15 de setembro** mediante o envio do link público do **Google Colab** contendo todo o código executado, saídas visíveis e comentários dissertativos markdown respondendo às análises solicitadas.

Dataset Disponibilizado: Utilize o arquivo anexo `servidores_ti.csv` contendo 500 registros de telemetria operacional de servidores.

2. Estrutura do Conjunto de Dados (servidores_ti.csv)

O arquivo possui as seguintes colunas que devem ser manipuladas via biblioteca pandas:

Coluna	Tipo	Descrição
servidor_id	Inteiro / String	Identificador único do servidor monitorado.
tipo_rede	Categórica	Tipo de infraestrutura (AWS, Azure, On-Premise).
uso_cpu	Contínua	Percentual médio de utilização da CPU (0 a 100%).
uso_memoria	Contínua	Percentual médio de utilização de memória RAM (0 a 100%).
latencia_rede_ms	Contínua	Latência média da rede em milissegundos.
taxa_pacotes_perdidos	Contínua	Percentual de pacotes de rede perdidos.
status_alerta	Binária	Indicador de falha iminente (0 = Saudável, 1 = Falha Iminente).

3. Tarefas Práticas do Exercício Programa

Parte 1: Manipulação com Pandas, Estimadores e Intervalos de Confiança

Utilizando a biblioteca pandas, carregue o conjunto de dados e execute os cálculos estatísticos descritivos:

- Calcule a média amostral ($\bar{x}$) e a variância amostral (s^2) para as variáveis uso_cpu e latencia_rede_ms.
- Construa formalmente um **Intervalo de Confiança de 95%** para a média verdadeira do uso_cpu de toda a população de servidores utilizando a distribuição t de Student (ou Z, justificado pelo tamanho amostral). Interprete o significado prático do intervalo obtido.

Parte 2: Teste de Hipóteses (χ^2 - Qui-Quadrado de Independência)

Investigue se há dependência estatística entre o tipo de infraestrutura onde o servidor opera (tipo_rede) e a propensão a falhas (status_alerta):

- Construa uma tabela de contingência cruzando tipo_rede e status_alerta por meio da função apropriada do pandas.
- Aplice o teste Qui-Quadrado de Independência considerando um nível de significância de $\alpha = 0.05$. Formule claramente a hipótese nula (H_0) e a alternativa (H_1), avalie o p-valor obtido e conclua analiticamente.

Parte 3: Redução de Dimensionalidade com PCA (Principal Component Analysis)

Prepare as métricas quantitativas contínuas para alimentar os modelos preditivos:

1. Selecione as colunas quantitativas: `uso_cpu`, `uso_memoria`, `latencia_rede_ms` e `taxa_pacotes_perdidos`.
2. Padronize os dados utilizando escalonamento de média zero e variância unitária.
3. Aplique o algoritmo **PCA** para projetar o espaço multidimensional em exatamente **2** Componentes Principais (**PC1** e **PC2**). Analise a proporção da variância explicada individual e acumulada.

Parte 4: Classificação Supervisada com KNN (K-Nearest Neighbors)

Construa um modelo preditivo baseado nas componentes principais obtidas:

1. Defina as features preditoras (**X**) utilizando as componentes principais do PCA e o vetor alvo (**y**) com a coluna `status_alerta`.
2. Divida o conjunto de dados em Treino (**70%**) e Teste (**30%**) com semente aleatória fixa (ex: `random_state=42`).
3. Instancie e treine um classificador **KNN** configurado com **K = 5** vizinhos.
4. Avalie o modelo gerando a matriz de confusão e o relatório de classificação completo (precisão, revocação e F1-score). Escreva uma análise crítica sobre o impacto operacional dos *falsos negativos* em um ambiente corporativo de TI.

4. Critérios de Avaliação

- **Originalidade e Individualidade:** Por se tratar de um trabalho individual, cópias de códigos ou interpretações idênticas entre alunos resultarão em nota zero.
- **Implementação Correta:** Uso correto das bibliotecas `pandas`, `scipy` e `scikit-learn` sem erros de execução no Colab.
- **Fundamentação Crítica:** Qualidade das explicações teóricas e interpretações dos testes estatísticos e métricas de machine learning nas células de texto do caderno.