



Inferência Estatística

Aula 1 – Apresentação da disciplina

Prof. Msc. Kyung Moo Kim
EMAIL_DO_PROFESSOR
kyung.kim@impacta.edu.br

Sumário

- Apresentação da disciplina
- Apresentação de variáveis
- Tipos de Escalas
- Apresentação de software estatístico.

Apresentação de disciplina

- Nome da disciplina: Inferência Estatística
- Turma - Ciências da computação - 6 CC
- Prof. Msc. Kyung Moo Kim
- Dias da disciplina : Terça e Quinta - feira.

Apresentação da disciplina

Avaliação

2 avaliações parciais com datas a ser divulgadas posteriormente (plano de ensino).

1 avaliação oficial - data no plano de ensino.

Média de AP = $(Ap1 + Ap2) * 0.5$

Média final = $0.3 * \text{Média de AP} + 0.4 * \text{prova oficial} + 0.3 * \text{PAI}$.

Apresentação da disciplina



Se média final ≥ 6 e frequência $\geq 75\%$ -> Aprovado.

Se media final < 6 e frequência $< 75\%$ -> Reprovado.

Qualquer aluno pode realizar a prova substitutiva tanto para melhorar a nota assim como para aprovação. O aluno deverá se inscrever e pagar a taxa correspondente até a data limite - ver o calendário.

Para praticar será fornecido lista de exercício pelo professor.

Bibliografia



Conceito de variável

Em estatística, uma **variável** é qualquer característica ou atributo mensurável que pode assumir diferentes valores entre os indivíduos ou objetos de uma pesquisa (como idade, peso ou nível de escolaridade).

A **análise multivariada** é o conjunto de métodos estatísticos que examina múltiplas variáveis simultaneamente para compreender como elas se relacionam e influenciam um fenômeno

Tipificação de variável

Em estatística são apresentado 2 tipos de variável:

1- Qualitativas (ou Categóricas): Representam características, grupos ou categorias (ex: sexo, cor dos olhos, estado civil).

2 - Quantitativas (ou Numéricas): Representam valores numéricos e podem ser discretas (números inteiros, como número de filhos) ou contínuas (valores com casas decimais, como altura ou temperatura)

Variável estatística

variável estatística, uma combinação linear de variáveis com pesos empiricamente determinados.

As variáveis são especificadas pelo pesquisador, sendo os pesos determinados pela técnica multivariada para atingir um objetivo específico.

Uma variável estatística de n variáveis ponderadas (X_1 até X_n) pode ser enunciada matematicamente como:

Valor da variável estatística = $w_1X_1 + w_2X_2 + w_3X_3 + \dots + w_nX_n$

X_n é a variável observada e w_n é o peso determinado pela técnica multivariada.

Exemplo de variável estatístico

Score de crédito: Em m banco para aprovar o crédito de um cliente pode utilizar as seguintes variáveis:

X1 : renda (em reais)

X2: idade (em anos)

X3 : histórico de dívidas atrasadas.

$$\text{Score} = 0.5X1 + 0.1X2 - 0.4X3.$$

Exemplo - Como interpretar os dados

2. Interpretando os Pesos (w)

- $w_1 = 0,5$: A renda tem forte impacto positivo. Quanto maior a renda, maior o score.
- $w_2 = 0,1$: A idade tem um impacto positivo, mas muito baixo.
- $w_3 = -0,4$: O histórico de dívidas tem um impacto negativo pesado. Cada atraso derruba o score.

Aplicação Prática

Se um cliente específico tem Renda = 5 (em milhares), Idade = 30 e Dívidas = 0, o banco aplica os dados na combinação linear para gerar um **único valor unificado**:

$$\text{Score} = 0,5 \times 5 + 0,1 \times 30 - 0,4 \times 0$$

$$\text{Score} = 2,5 + 3 - 0 = 5,5$$

O banco não precisa olhar três relatórios separados. Ele olha apenas para o resultado da **variável estatística (5,5)** para tomar a decisão de forma automatizada.

Escala de medida - Definição

São regras ou critérios que determinam como as variáveis são classificadas, quantificadas e organizadas, isto é, las definem **a natureza matemática de um dado** e, conseqüentemente, quais operações matemáticas e testes estatísticos podem ser aplicados a ele.

Tipos de escalas de medidas

Escalas de medida não - métrica:

Medidas que descrevem diferenças em tipo ou natureza, indicando a presença ou ausência de uma característica ou propriedade, são chamadas de **dados não-métricos**.

Esta escala divide em duas categorias: Nominiais e ordinais.

As duas categorias

As duas categorias são :

Nominal	Ordinal
Comportamento de consumidor	Pesquisa de opinião
Perfil socioeconômico	Mercado de trabalho
Tecnologia	Educação - Nivel
Geografia	Classe socioeconomica
Logística/ Operações	Experiência de usuário

Tipo de escala Métrica

Escala de medida métrica

Os **dados métricos** são utilizados quando indivíduos diferem em quantia ou grau em relação a um atributo em particular.

As medidas refletem quantidade ou grau relativo e são apropriadas para atributos envolvendo quantia ou magnitude, como o nível de satisfação ou compromisso com um emprego.

Categoria de escalas métricas

Escala Intervalar :**é uma escala de medida quantitativa** onde a distância entre os números é precisa e igual, mas **o ponto zero é arbitrário (relativo)**. Isso significa que o número zero não representa o vazio ou a "ausência total" da propriedade medida.

Exemplos:

Índices de Satisfação do Cliente (CSAT): Notas padronizadas de 100 a 500 pontos para medir a experiência com um serviço.

Escores de Imagem de Marca: Pontuações de -3 (Imagem Muito Ruim) a +3 (Imagem Muito Boa). Note que o escore 0 aqui é neutro, não significa ausência de imagem.

Escore de Estresse ou Burnout: Questionários de R

Categoria de Escala Métrica

A escala de razão é conhecido também como de proporção. É a escala mais importante pois, envolve as outras escalas anteriormente mencionada.

A diferencia crucial comparada à escala intervalar é que nesta escala possui o conceito de **zero absoluto**.

Escala métrica de proporção

Definição de zero absoluto: Significa a ausência total e real da característica que está sendo medida.

Se uma medida é zero simplesmente, ele não existe.

Obs. Por causa da definição de zero absoluto é que pode se realizar as operações aritméticas.

Exemplos onde aparece zero absoluto

1. Faturamento ou Renda (Exemplo Empresarial/Econômico)

- **O Zero Absoluto:** Se uma empresa faturou R\$ 0 neste mês, significa ausência total de faturamento (ela não ganhou nada).
- **A Razão (Proporção):** Uma empresa que fatura R\$ 100.000 ganha **exatamente o dobro** de uma que fatura R\$ 50.000.

2. Idade ou Tempo (Exemplo Demográfico)

- **O Zero Absoluto:** O momento do nascimento (0 anos, 0 meses, 0 segundos) é o ponto de partida real do tempo de vida. Não existe idade negativa.
- **A Razão (Proporção):** Uma pessoa de 40 anos tem **o dobro** da idade de um jovem de 20 anos.

Exemplo de zero absoluto

3. Número de Clientes ou Unidades Vendidas (Exemplo de Marketing)

- **O Zero Absoluto:** 0 clientes significa que ninguém comprou o produto.
- **A Razão (Proporção):** Uma loja que vendeu 10 sanduíches vendeu **a metade** da loja que vendeu 20 sanduíches.

4. Peso e Altura (Exemplo Biológico/Físico)

- **O Zero Absoluto:** 0 kg significa ausência total de massa.
- **A Razão (Proporção):** Um pacote de 10 kg é **cinco vezes mais pesado** que um pacote de 2 kg.

Impacto da escolha de escala

1. **Evitar Erros de Cálculo:** Dados não métricos codificados em números (ex: 1 = Homem, 2 = Mulher) **não** admitem operações como médias aritméticas.
2. **Critério de Seleção:** A natureza dos dados (métricos vs. não métricos) é o fator decisivo para escolher a técnica estatística correta.
3. **Análise das Variáveis:** É obrigatório classificar o tipo de escala tanto das variáveis **dependentes** quanto das **independentes**.

O que é inferência estatística?

É a área da estatística que utiliza dados de uma **amostra** para extrair conclusões, estimativas e generalizações sobre toda a **população**, medindo o grau de incerteza (confiabilidade) dessa generalização

O que é inferência estatística

Objetivo: Estudar uma população inteira quando é impossível (ou muito caro) analisar todos os indivíduos

O Processo:

1. Coleta-se uma **amostra** (um subconjunto representativo).
2. Calculam-se os dados dessa amostra (ex: média amostral).
3. **Infer-se** (estende-se) esse resultado para a **população** original.
4. **Ferramentas Principais:** Testes de hipóteses (como o Teste t, ANOVA) e Intervalos de Confiança entre outras.

Dizer que *"80% das lâmpadas de uma fábrica duram 5 anos"* sem precisar testar todas as lâmpadas da fábrica até queimarem. Testa-se apenas um lote (amostra) e faz-se a inferência para o resto da produção (população)

Diferença entre população e amostra.



Diferenciação entre população e amostra

Em estatística devemos diferenciar os conceitos de população e amostra.

População: Refirimos a conceito de população a todos os elementos presente no conjunto, ou seja, o conjunto todo.

Amostra: Parte de uma população (Subconjunto)

Exemplo.

A população de Brasil: 215 milhões de pessoas.

Para realizar uma pesquisa eleitoral, uma empresa escolhe um pequeno número de pessoas (em torno de 2000 pessoas). Então em estatística a **população** seria 215 milhões de pessoas e **amostra** seria 2000 pessoas.

Exercício

Identifique população e amostra.

- a) Em uma pesquisa de mercado 340 pessoas preferiram um certo produto. Dessas pessoas 120 preferem um outro produto também.

- b) Em uma pesquisa eleitoral para prefeito a cidade A tem 400000 pessoas. Dessas pessoas 140 mil preferiram o candidato B.

Rotulos

- Definição: São as etiquetas de identificação que damos para os valores de uma escala não métrica (ordinal ou nominal).
- Outra forma de definir: são nomes textuais atribuídos a códigos numéricos apenas para fins de organização de banco de dados.

Exemplo:

variável : Estado civil

Código no Software : 1, 2, 3

Rótulo (Labels) : 1 = Solteiro, 2= Casado, 3 = Divorciado.

Rótulos em ciência de dados/ ML.

Quando conectamos a estatística com modelos modernos de predição, o **rótulo (label)** é a **variável resposta, dependente ou o "alvo"** que o modelo está tentando prever ou inferir.

- **O que são:** É a informação de "gabarito" que diz a qual categoria ou valor uma observação amostral pertence.
- **A função na Inferência:** Treinar o modelo matemático para que ele aprenda a fazer inferências corretas em novos dados que ainda não possuem rótulo.

Dados brutos (X): Histórico de crédito, renda, idade.

Rótulo (Y): Inadimplente ou Bom Pagador.

O modelo usa a amostra rotulada para **inferir** se futuros clientes serão bons pagadores ou não

Exemplo em ciência de dados/ML

Seja o seguinte banco de dados

Cliente	Renda (R\$)	Dívidas Atuais (R\$)	RÓTULO (Label - Y)	<i>O que o rótulo significa</i>
1	5.000	2.000	0	Pagou o empréstimo
2	2.500	8.000	1	Não Pagou (Inadimplente)
3	12.000	1.500	0	Pagou o empréstimo
4	3.000	5.000	1	Não Pagou (Inadimplente)

Exemplo em ciência de dados/ML

Suponhamos que o banco tem um novo cliente com os seguintes dados:

renda : R\$ 2800

dívida : R\$ 7500.

Qual será o rótulo (Y)? (o banco ainda não sabe sobre o comportamento do cliente se é bom pagador)

sol: pelo histórico do banco de dados tira-se a conclusão que o cliente não pagou. Nega o empréstimo.

Tabelas cruzadas

Para Hair uma tabela cruzada são “ferramentas fundamentais para analisar a interdependência entre variáveis categóricas (não métricas). Elas servem como base para técnicas avançadas, como a Análise de Correspondência, que converte dados qualitativos em mapas perceptuais para visualização de associações.”

Propriedades das tabelas cruzadas

Foco Categórico: Ideal para o cruzamento de variáveis não métricas.

Simetria de Interdependência: Avalia o relacionamento mútuo entre variáveis.

Captura Não Linear: Detecta associações que a regressão linear simples não consegue identificar.

Base Multivariada: Serve como ponto de partida para análises avançadas de mapeamento e redução de dados (como Análise de Correspondência).

Exemplo - Tabela cruzada

Pesquisa de satisfação de uma empresa. Suponhamos que foram pesquisadas 120 pessoas em relação à tipo de plano e cliente e satisfação ao tipo de plano de cliente.

Consideremos que:

tipo de plano : Premium ou básico

satisfação : satisfeito ou insatisfeito.

Após a pesquisa obteve a seguinte tabela:

Exemplo de tabela cruzada

Tipo de Plano / Satisfação	Satisfeito	Insatisfeito	Total por Plano
Plano Premium	45	15	60
Plano Básico	20	40	60
Total por Satisfação	65	55	120 (Amostra Total)

Clientes Premium: $45 : 60 = 75\%$ estão Satisfeitos
25% Insatisfeitos.

Clientes Básicos: $20 : 60 = 33,3\%$ estão Satisfeitos
66,7% Insatisfeitos.

Exemplo de tabela cruzada

Conclusão : Evidência de Associação:
Existe uma forte diferença de comportamento entre os grupos. Os clientes do plano *Premium* estão significativamente mais satisfeitos (75%) do que os clientes do plano *Básico* (33,3%).