



Inferência estatística

Aula 02– Organização de dados

Prof. MSc. Kyung Moo Kim
EMAIL_DO_PROFESSOR
kyung.kim@impacta.edu.br

Sumário

- Organização de dados
- Box - Plot - Diagrama de caixa
- Organização de dados em tabela de frequência

Organização de dados

Quando faz uma certa pesquisa no mercado, os dados estão desorganizados, então para melhor estudo dos dados coletados podem ser organizados em grupos de intervalos. Após essa organização de dados brutos podem ser representados graficamente de diferentes formas.


- a) gráfico de setores.
- b) gráfico de barra .
- c) histograma.
- d) box- plot

Gráfico de setores




Os gráficos de setores representam os dados em percentagem que é proporcional da área a ser representada.

Gráfico de Barra



Histograma



é um tipo de gráfico de barra que mostra a distribuição de dados.

Diferença entre gráfico de barra e histograma

Um histograma é usado para dados contínuos, em que os intervalos de classe representam a extensão dos dados.

Os dados podem ser agrupados em classes e, para representar essas classes, utiliza-se o histograma, que é um gráfico de barras justapostas; cada barra indica uma classe.

Já um gráfico de barra é um gráfico de variáveis categóricas ou discretas.

Polígono de frequência

Um polígono de frequência é um gráfico que se realiza através da união dos **pontos** mais altos das colunas num histograma de frequência (que utiliza colunas verticais para mostrar as frequências).




Fonte: <http://www.amma.com.pt?p=6838>

Box Plot - Diagrama de caixa


Segundo o site opencadd o box plot é uma ferramenta gráfica utilizada para ilustrar um conjunto de dados. Por meio dele, é possível visualizar a distribuição de dados com base em cinco estatísticas:

- o mínimo;
- o primeiro quartil (Q1);
- a mediana - segundo quartil (Q2);
- o terceiro quartil (Q3);
- o máximo.

Box - plot



Elementos de boxplot



Características de um boxplot

Esta forma de representação mostra a variação de dados observados através de quartis.


Os quartis é um conceito utilizado em Estatística descritiva para indicar que um conjunto de dado está representado o 25 por cento da população.

Os quartis são:

- a) Primeiro quartis: Representa os 25 por cento mais baixo do conjunto da amostra.
- b) Segundo quartis: Representa os 50 por cento do conjunto da amostra.
- c) Terceiro quartis: Representa os os outros 25 por cento mais alto do conjunto da amostra


A assimetria no boxplot

Os box-plot pode apresentar diferentes formas de assimetria e com isto apresenta também valores extremos como podemos ver na figura a seguir



Assimetria de boxplot e curva normal

Distribución simétrica
o en forma de
campana (Normal)




Se cumple:

$$|X_{\min} - Q_1| = |X_{\max} - Q_3|$$

$$|Q_2 - Q_1| = |Q_2 - Q_3|$$

$$Q_2 = \bar{X}$$


Distribución asimétrica
negativa (cola hacia
la izquierda)



Se cumple:

$$\bar{X} < Q_2 = M_e < M_o$$

Distribución asimétrica
positiva (cola hacia
la derecha)



Se cumple:

$$\bar{X} > Q_2 = M_e > M_o$$

Donde: $X_{\min}$ → valor mínimo, $X_{\max}$ → valor máximo, Q_1, Q_2, Q_3 → Cuartiles, $\bar{X}$ → media, M_e → mediana, M_o → moda

Características

- **Assimetria Positiva (à direita):** A mediana está mais próxima do primeiro quartil ($Q1$), a parte superior da caixa é maior que a inferior e a haste superior é consideravelmente mais longa.
- **Assimetria Negativa (à esquerda):** A mediana está mais próxima do terceiro quartil ($Q3$), a parte inferior da caixa é maior e a haste inferior é mais longa.
- **Simétrica:** A mediana está no centro da caixa e as hastes têm comprimentos aproximados.

Exercício

O que pode observar nos 4 histogramas?




Tabela de frequência

O que é uma tabela de frequência??

É uma tabela que divide em três colunas:

- a) Coluna das classes: os dados estão dentro de um intervalo que é definido pelo pesquisador.
- b) Coluna de frequência absoluta: Indica a quantidade de elementos que estão na classe. Aqui, o pesquisador deve fazer contagem manual dos valores pesquisados.
- c) Coluna de frequência relativa: Indica a porcentagem dos elementos presente na classe.

Frequência

Frequência é a quantidade de elementos que apresentam nos conjuntos de dados.

Dois tipos de frequência:

- a) Frequência absoluta: Quantidade de elementos presente nos dados.
- b) Frequência relativa: Porcentagem de quantidade de elementos presente nos conjuntos de dados.

Frequência acumulada

Há dois tipos de frequência acumulada:

- a) Frequência acumulada absoluta.
- b) Frequência acumulada relativa.

classe	freq. abs.	freq. abs. ac.	freq. relativa	freq. rel. ac.
[0, 10[	12	12	$\frac{12}{56} = 0,2142$	0,2142
[10, 20[	13	12+13= 25	$\frac{13}{56} = 0,2321$	0,4463
[20, 30[	16	25+16 =41	$\frac{16}{56} = 0,2857$	0,732
[30, 40[	4	41+4= 45	$\frac{4}{56} = 0,071$	0,803
[40, 50[	7	45+7=52	$\frac{7}{56} = 0,125$	0,928
[50, 60[	4	52+4=56	$\frac{4}{56} = 0,071$	0,999
Total	56		$0,99942 \approx 1$	

Quantidade de classes

Para cálculo de quantidade de classe vamos a usar a expressão a seguir:

1. cálculo de amplitude = Máx - Min.

2. cálculo de quantidade de classe:

$$\text{classe} = \frac{\text{amplitude}}{\text{tamanho}}$$

Tamanho é dado no exercício.

Cálculo de quantidade de classes

Exemplo vamos a considerar a tabela altura de crianças ao nascer.

36.6	35.1	37.7	37.2	38.0
38.1	37.6	36.6	35.4	38.7
35.0	36.0	36.4	37.8	36.3
37.8	37.5	38.3	36.6	37.3
37.6	37.9	37.4	38.5	37.0
38.5	36.5	35.0	38.3	38.2

Para montar a tabela de frequência e consequentemente, temos que calcular a quantidade de classes.

Quantidade de classes

Para esse último cálculo vamos a considerar o mínimo e o máximo. Assim, temos

Intervalo : Máx - Min = 38.7 - 35.0 = 3.7

Considerarmos que o tamanho de intervalo é cada 0.5, concluimos que :

$$\frac{3.7}{0.5} = 7.4 \approx 8$$

logo, concluimos que terá 8 classes.

Exercício.

Durante uma auditoria de performance nos sistemas de um grande banco digital brasileiro em **janeiro de 2025**, a equipe de monitoramento coletou o **tempo de processamento (em segundos)** de uma amostra de **40 queries críticas** de banco de dados. O objetivo é identificar padrões de lentidão para otimizar o tempo de resposta aos usuários.

Dados coletados (segundos):

150.0, 155.0, 160.0, 160.0, 177.0, 155.0, 153.0, 160.0, 161.0,
168.0, 154.0, 152.0, 163.0, 161.0, 160.0, 150.0, 152.0, 162.0,
159.0, 162.0, 165.0, 173.0, 167.0, 182.0, 165.0, 177.0, 176.0,
176.0, 178.0, 154.0, 158.0, 150.0, 154.0, 174.9, 168.6, 176.4,
185.2, 167.6, 167.6, 185.7

Exercício

Com base nesses dados, realize as seguintes tarefas estatísticas:

1. **Cálculo de Classes:** Determine a quantidade de classes
2. **Tabela de Frequências:** Construa a tabela utilizando um intervalo (amplitude) de **5 em 5 segundos**.
3. **Distribuição:** Encontre a **Frequência Absoluta** e a **Frequência Relativa** para cada intervalo.
4. **Análise de TI:** Com base na tabela, qual a porcentagem de queries que levam mais de 175 segundos para serem processadas?"