



Inferência estatística

Aula 03 – Estatística Univariada - Revisão

Prof. Msc. Kyung Moo Kim
EMAIL_DO_PROFESSOR
kyung.kim@faculdadeimpacta.com.br

Sumário

- Estatística univariada
- Medida de tendência central.
- Medida de dispersão.

Estatística Univariada

O que é ?

examina uma única variável isoladamente para entender seu comportamento (ex: calcular a média de idade de um grupo)

Medidas de tendência central

As medidas de tendência central são medidas estatísticas utilizadas para representar um conjunto de dados como um todo, identificando as características apresentadas pelo conjunto.

As principais medidas de tendência central são:

1. Média aritmética
2. Moda
3. Mediana.

Média aritmética simples

A média aritmética simples de um conjunto dado $X = \{x_1, x_2, \dots, x_n\}$ é dado pela expressão:

$$\bar{X} = \frac{x_1 + \dots + x_n}{n}$$

Exemplo

Sejam os dados a seguir que representa o salário de 6 funcionários de uma pequena empresa de TI em São Paulo:

funcionário	Salário (Reais)
1	3400
2	5400
3	2300
4	2400
5	1900
6	1500

Logo, a média salarial da empresa é dado por:

$$\overline{\text{salario}} = \frac{3400 + 5400 + 2300 + 2400 + 1900 + 1500}{6} = 2816,67.$$

Média ponderada

definição: Seja $X = \{x_1, \dots, x_n\}$ os conjuntos de dados e seja $p = \{p_1, \dots, p_n\}$ os pesos correspondentes a cada x_i dos conjuntos de dados. Definimos média ponderada:

$$\bar{X} = \frac{x_1 \times p_1 + \dots + x_n \times p_n}{p_1 + \dots + p_n}$$

Exemplo

Em uma escola a média anual dos alunos é calculado através de média ponderada. Ou seja, para cada nota de bimestre vai multiplicar pelo peso correspondente e depois somar os pesos e dividi- lo a soma da nota com a soma dos pesos.

Suponhamos que Mariana obteve as seguintes notas nos quatro bimestres em Ciências.

bimestre	Peso	Nota
1	2	6,7
2	2	7
3	4	8
4	5	8

Qual será a média de Mariana em ciências??

$$\overline{nota} = \frac{6,7 \times 2 + 7 \times 2 + 8 \times 4 + 8 \times 5}{2 + 2 + 4 + 5} = 7,6$$

Média aritmética nos classes de intervalo

classe	freq. abs.(fa)	ponto médio (médio)	$fa \times \text{médio}$
[0, 10[	12	5	$12 \times 5 = 60$
[10, 20[	13	15	$13 \times 15 = 195$
[20, 30[	16	25	$16 \times 25 = 400$
[30, 40[	4	35	$4 \times 35 = 140$
[40, 50[	7	45	$7 \times 45 = 315$
[50, 60[	4	55	$4 \times 55 = 220$
Total	56	xxx	xxx

$$\bar{x} = \frac{60 + 195 + 400 + 140 + 315 + 220}{56} = \frac{1330}{56} = 23,75.$$

Observação

Como vimos na aula 2 em estatística há uma diferença entre a definição de população e amostra. Os cálculos estatísticos de medidas de tendência central e de dispersão (próximo tópico) esses dois conceitos são considerados. No cálculo de médias (amostral e populacional) não muda porém muda o símbolo. No caso de média populacional usa-se o símbolo μ (mu) e para a média amostral usa-se $\bar{x}$

Mediana.

Dado um conjunto de dados $X = \{x_1, x_2, x_3, \dots, x_n\}$ definimos como a mediana ao valor central desse conjunto de dados.

Os conjuntos de dados podem ser quantidades pares ou ímpares.

Nesse caso, podemos encontrar de forma simples esses valores:

Em primeiro momento vamos ordenar os dados de forma crescente e após esse processo contamos ou verificamos a quantidade de elementos presente no conjunto. Assim, Quando o n , isto é a quantidade dados é par a mediana será a media aritmética entre os dois valores médios.

Quando n , isto é, a quantidade de dados é ímpar, mediana será o valor que se encontra exatamente na metade dos dados.

Mediana de conjunto de números ímpares de elementos.

Exemplo: Sejam os valores:

4,7,8,9,3,12,13,43,55,65,75,33,15,4,4,3,1,2.

Ordenando os valores de forma crescente:

1,2,3,3,4,4,4,7,8,9,12,13,15,33,43,55,65,75.

A mediana é :

$$\frac{8 + 9}{2} = 8,5.$$

Mediana de números pares de elementos.

Exemplo: Sejam os valores:

4,7,8,9,3,12,13,43,55,65,75,33,15,4,4,3,1.


Ordenando os valores de forma crescente:

1,3,3,4,4,4,7,8,9,12,13,15,33,43,55,65,75.

A mediana é : 9. Conta-se 8 de esquerda para direita e 8 de direita para esquerda.

Cálculo de mediana através de histograma

Consideremos a turma de estatística de uma faculdade e apresentou o seguinte histograma:



$$\frac{68 - 62}{36\%} = \frac{M_d - 62}{18\%}$$

$$M_d = 65 \text{ kg.}$$

Moda

Seja o conjunto de dados $X = \{x_1, x_2, \dots, x_n\}$ defina-se moda ao maior quantidade de elemento repetido dentro desse conjunto de dados.

Observação: Quando no conjunto de dados há dois elementos mais repetidos é chamado de ***bimodal***.

Quando dentro de dados há mais de 2 modas chamaremos de ***multimodal***.

Exemplo


Exemplo: Sejam os valores:

4,7,8,9,3,12,13,43,4,55,65,75,33,15,5,4,6,2,1,1,4,4,6,
4,8,4,4,4,3,1,1,1.

Neste exemplo podemos ver que o número 4 é moda pois tem maior quantidade de elementos, neste caso 8 elementos.

Identificação de Moda no histograma

Consideramos as alturas de alunos de disciplina inferência estatística de uma faculdade resultou o seguinte histograma. A moda é o ponto de interseção dos segmentos.



Exemplo

Utilizando a expressão:

$$M_o = l_i + \frac{h \cdot (F_i - F_{i-1})}{(F_i - F_{i-1}) + (F_i - F_{i+1})}$$

Substituindo os valores obtemos:

$$18 + \frac{4 \cdot (11 - 0)}{(11 - 0) + (11 - 6)} = 18 + \frac{44}{16} = 18 + 2,75 = 20,75 \text{ anos.}$$

Influência de outliers (valores atípico) em medidas de tendência central.

Qual é a influência de outliers em medidas de tendência central?

Isso depende de se o outliers estão no limite superior ou inferior.

No primeiro caso, a média aumenta e no segundo caso a média diminui (trabalha com todos os dados).


Nos outros casos:

mediana: permanecerá na próxima a posição central dos dados.

Moda: Não afeta. Porém, afetará quando o outliers é a moda.

Exercício


Encontre a média , mediana e moda do gráfico a seguir.



Observação: Considere que todos os intervalos de classe do histograma são fechados à esquerda e abertos à direita.

Exercício

Encontre a média , mediana e moda do gráfico a seguir.



Observação: Considere que todos os intervalos de classe do histograma são fechados à esquerda e abertos à direita.

Medidas de dispersão

A medida de dispersão são utilizado para ver o grau de variação que há entre a media e os dados apresentados. Os principais medidas de dispersão são:

- a) variância.
- b) desvio padrão.
- c) amplitude.
- d) Coeficiente de variação.
- e) Amplitude Interquartil.

Variância para uma população

Variância é um parâmetro que indica quão distante esta da media. Se o valor de variância é menor está mais próximo da media e o valor da variância é maior quer dizer que está mais distante da média.

Seja o conjunto $X = \{x_1, x_2, \dots, x_n\}$ um conjunto de dados definimos a variância como

$$\text{var}(x) = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}.$$

onde, $\bar{x}$ é a média aritmética.

Interpretação : Quanto maior a variância, maior a dispersão nos dados.

Exemplo

Seja o conjunto de dados: $X = \{3, 1, 4, 6, 8, 9\}$. Vamos calcular a variância.

Passo 1. Cálculo da média aritmética

$$\bar{x} = \frac{3 + 1 + 4 + 6 + 8 + 9}{6} = 5,16.$$

Passo 2. Calcular a expressão $(x_i - \bar{x})^2$ para cada dado e somar.

$$(3 - 5,16)^2 + (1 - 5,16)^2 + (4 - 5,16)^2 + (6 - 5,16)^2 + (8 - 5,16)^2 + (9 - 5,16)^2 = 46,8336.$$

Exemplo de Variância

Passo 3. O valor obtido no 2 divide-se pelo número de elementos presente no conjunto.

$$\frac{46,8336}{6} = 7,8056$$

Observação: maior variância: os dados estão mais distantes da media e quanto menor variância os dados estão mais próximo da média.

Cálculo de variância para uma amostra

Em estatística amostra é uma pequena fração de uma população (um subconjunto).

Para calcular a variância para uma amostra temos a expressão:

$$var(x) = \frac{\sum_{i=1}^k (x_i - \bar{x})^2}{n-1}$$

Desvio padrão

O desvio padrão indica qual é o “erro” se quiséssemos substituir um dos valores coletados pelo valor da média.

O cálculo será dado

$$S = \sqrt{\text{var}(x)}$$

do exemplo anterior

$$S = \sqrt{7,8056} = 2,7938$$

Desvio Padrão

Mas...o que significa da definição é o “erro” se quiséssemos substituir um dos valores coletados pelo valor da média?

Consideramos o conjunto de dado $X=\{3,1,4,6,8,9\}$. Então o “erro” cometido ao substituir pelo valor da média a um dis valores será dado por:

$$X = 5,16 \pm 2,7938$$

Amplitude

Amplitude é a diferença entre o maior valor e o menor valor do conjunto de dado.

Seja o conjunto de dados: $X = \{3, 1, 4, 6, 8, 9\}$

A amplitude do conjunto será de

$$9 - 1 = 8$$

Coeficiente de variação

Uma medida de dispersão relativa que compara a variabilidade de conjuntos de dados com médias diferentes, expressa como porcentagem. É útil quando as unidades de medida são diferentes.

$$CV = \frac{S}{\overline{X}} \times 100\%$$

S: desvio padrão

$\overline{X}$: média

Coeficiente de variação

O CV indica o nível de precisão dos dados. Quanto menor o CV, mais homogêneos são os dados e maior é a precisão do estimador em relação à média; já um CV elevado indica alta dispersão e menor confiabilidade da estimativa.

em outras palavras....

O CV indica o quão precisos são os dados. Quanto menor o CV, mais concentrados os dados estão em torno da média (maior precisão), enquanto um CV maior mostra que os dados estão muito distantes da média (baixa precisão)."

Exemplo

Estabilidade de Latência (Redes e APIs)

Imagine que você está monitorando dois microsserviços e quer saber qual deles tem a latência mais **instável** (o que gera uma experiência ruim para o usuário).

- **Serviço A (Autenticação):**
 - Média de resposta: **20ms**
 - Desvio Padrão: **5ms**
 - $CV = (5 / 20) \times 100 \% = 25\%$
- **Serviço B (Processamento de Imagem):**
 - Média de resposta: **500ms**
 - Desvio Padrão: **50ms**
 - $CV = (50 / 500) \times 100\% = 10\%$

Visão de TI: Embora o Serviço B varie 50ms (numericamente mais que os 5ms do A), o **Serviço A é proporcionalmente muito mais instável**. Em TI, chamamos isso de latência "jittery". O Serviço B é mais previsível para o usuário final.

Amplitude Interquartil

A amplitude interquartil é uma das medidas de dispersão mais importantes de estatística. Esta medida estatística foca na dispersão de dados em torno da mediana.

Pontos importantes: A amplitude interquartil ignora os 25% menores valores e 25% dos maiores valores.

$$\text{IQR} = Q3 - Q1 \quad Q1 = \frac{n+1}{4} \quad Q3 = \frac{3(n+1)}{4}$$

n: número total de elementos

Amplitude Interquartil - Robustez

Resistente a Outliers: Se você tiver um valor "absurdo" (muito alto ou muito baixo) no seu conjunto de dados, ele não afetará o IQR, pois ele olha apenas para o meio da distribuição.

Ideal para Dados Assimétricos: Quando seus dados não seguem uma curva perfeita (estão "puxados" para um lado), o IQR é muito mais confiável que a média.

Exemplo

Sejam os valores:

12,43,54,76,87,42,12,65,87,5,8,16,7,89,98,32,13

$n = 17$

Ordenando os valores : 5, 7, 8, 12, 12, 13, 16, 32, 42, 43, 54, 65, 76, 87, 87, 89, 98.

Aplicando a expressão : $(n+1)/4 = (17+1)/4$
 $= 4,5$. O número significa que está na posição entre 4 e 5 dos valores já ordenados. Assim,
O valor: $Q1 = (12+12)/2 = 12$.

Exemplo

Da mesma forma temos:

$$\frac{3(n+1)}{4} = \frac{3(17+1)}{4} = 13,5$$

Ou seja, os valores para o Q3 estão na posição 13 e 14. Esses valores são: 76 e 87. Logo,

$$Q_3 = \frac{76+87}{2} = 81,5$$

e, finalmente: $IQR = 81,5 - 12 = 69,5$.

Coeficiente de assimetria de Bowley

O **Coeficiente de Assimetria de Bowley** (também conhecido como Coeficiente Quartílico de Assimetria) é uma medida de assimetria que utiliza apenas os **quartis** da distribuição em vez de momentos estatísticos (como média e desvio padrão)

Este coeficiente é calculado através da seguinte expressão:

$$g_b = \frac{(Q_3 - Q_2) - (Q_2 - Q_1)}{Q_3 - Q_1}$$

este coeficiente é para medir a falta de simetria em um conjunto de dados.

Coeficiente de assimetria de Bowley







O valor deste coeficiente está delimitada entre -1 e 1.

$gb=0$: A distribuição é simétrica. A distância entre a primeira e a mediana é igual à distância entre mediana e terceira quartil.

$gb>0$: Assimetria positiva A distância $Q3$ é maior que entre $Q2$ e $Q1$. Cauda mais longa para os valores altos.

$gb<0$: Assimetria negativa. A distância entre a mediana e $Q1$ é maior que entre $Q3$ e $Q2$. Cauda mais longa para os valores baixo.

Imagem de assimetria box-plot e histograma



Curtose

Definição : é uma medida estatística que descreve o formato das caudas de uma distribuição de probabilidade em relação a uma distribuição normal.

O objetivo é indicar a frequência com que ocorrem **valores extremos** (outliers).

Observação

O que o curtose indica?

Uma **curtose alta** avisa que você deve se preparar para "surpresas" (eventos raros, mas intensos). Maiores chances de outliers.

Uma **curtose baixa** indica um processo mais estável e previsível, sem grandes saltos fora do comum. Dados mais espalhados.

Como calcular curtose

O cálculo de curtose é feito através da seguinte expressão:


$$\text{Curtose} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right)^2}$$

onde,

n: número de elementos

x_i : valor individual

$\bar{x}$: média dos dados.



Curtose em excesso

O cálculo de curtose em excesso é realizado através da expressão:

$$\text{curtose em excesso} = \text{curtose} - 3.$$

Resultado > 0 (Leptocúrtica): Curva pontiaguda, caudas pesadas (muitos outliers).

Resultado $= 0$ (Mesocúrtica): Distribuição Normal.

Resultado < 0 (Platicúrtica): Curva achatada, caudas leves (poucos outliers).

Exemplo

Seja $A = [3, 5, 7, 8, 9, 10, 4]$. $n = 7$, média de $A = 6,57$

$A[i]$	$A[i] - \text{média}$	$(A[i] - \text{média})^2$	$(A[i] - \text{média})^4$
3	-3,57	12,74	162,30
5	-1,57	2,46	6,027
7	0,43	0,184	0,0338
8	1,43	2,044	4,177
9	2,43	5,90	34,81
10	3,34	11,15	124,32
4	-2,57	6,60	43,56
Total	-----	41,078	375,22

Cálculo de curtose

finalmente,

$$\text{Curtose} = \frac{\frac{1}{7} \times 375,22}{(\frac{1}{7} \times 41,078)^2}$$

chegando a

$$\text{Curtose} = \frac{53,60}{34,43} = 1,556$$

concluimos que tem caúda leve - Plauticúrtica.


Ou seja, há pouco outliers e os dados muito espalhados

Influência de outliers em medidas de dispersão

Medida de dispersão	Influência dos outliers	Explicação
Amplitude (range)	Extremamente sensível	Como é calculada pela diferença entre o maior e o menor valor, qualquer outlier altera drasticamente o resultado.
Variância	Muito sensível	Valores extremos aumentam o quadrado das diferenças em relação à média, inflando a variância.
Desvio padrão	Muito sensível	Como é a raiz da variância, também cresce bastante com outliers.
Desvio absoluto médio (MAD)	Menos sensível	Mede a distância média em relação à mediana, sendo mais robusto contra valores extremos.
Intervalo interquartilício (IQR)	Pouco sensível	Baseado nos quartis ($Q3 - Q1$), ignora os extremos e foca na parte central dos dados.

Exercício

Encontre: Desvio padrão, CV ,Intervalo interquartil, coeficiente de Bowley e curtose do histograma a seguir:



Observação: Considere que todos os intervalos de classe do histograma são fechados à esquerda e abertos à direita.