



Inferência estatística

Aula 4 - Estatística bivariada

Prof. Msc. Kyung Moo Kim
EMAIL_DO_PROFESSOR
kyung.kim@faculdadeimpacta.com.br

Sumário

- Introdução
- Associação de variáveis: teste de Associação, de homogeniedade e de independência:
- Qualitativo - Qualitativo
- Teste Chi em Python

Introdução

Consideremos a seguinte tabela de dupla entrada:

$V \backslash Y$	Ensino Fundamental	Ensino Médio	Superior	Total
Capital	4	5	2	11
Interior	3	7	2	12
Outra	5	6	2	13
Total	12	18	6	36

onde, Y representa o grau de instrução e V região

Qual será a relação entre Y e V? Essa questão será resolvida através das técnicas que veremos nesta aula.

Associação de variáveis

Em estatística, **associação de variáveis** ocorre quando o conhecimento sobre o valor de uma variável nos dá informações sobre o provável valor de outra variável. Em termos simples: se uma muda, a outra tende a mudar também de forma previsível.

É importante notar que **associação não é necessariamente causalidade** (o fato de estarem ligadas não significa que uma causa a outra).

Associação de variável

Voltando à tabela

$V \backslash Y$	Ensino Fundamental	Ensino Médio	Superior	Total
Capital	4	5	2	11
Interior	3	7	2	12
Outra	5	6	2	13
Total	12	18	6	36

A pergunta é: A relação de nível de ensino está relacionado com ser de interior ou de capital?

Qualitativo - Qualitativo -> Chi quadrado.

Teste Chi - Quadrado

Teste Chi - Quadrado assim como outros teste já visto segue o mesmo roteiro.

1. Definir hipótese nula e alternada.
2. Calcular a região crítica.
3. Comparar com o nível de significância e analisar se rejeita ou não o valor calculado.

obs: O teste de associação, de independência e de homogeneidade segue o mesmo molde o que muda é o ponto 1.

Teste Chi - Quadrado

$V \backslash Y$	Ensino Fundamental	Ensino Médio	Superior	Total
Capital	4	5	2	11
Interior	3	7	2	12
Outra	5	6	2	13
Total	12	18	6	36

H0: Nível de ensino não está associado à região

H1: Nível de ensino está associado à região

teste de associação ou de independência.

Teste Chi - Quadrado

Para realizar teste Chi quadrado utilizamos a expressão:

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

O_{ij} : valor observado na posição i j da tabela.

E_{ij} : valor esperado na posição i j da tabela.

Teste Chi - Quadrado

O calculo de valor E_{ij} será realizado através da expressão:

$$E_{ij} = \frac{\text{Total da Linha } (n_i) \times \text{Total da Coluna } (n_j)}{\text{Total Geral}}$$

Teste Chi - Quadrado

Da tabela

$V \backslash Y$	Ensino Fundamental	Ensino Médio	Superior	Total
Capital	4	5	2	11
Interior	3	7	2	12
Outra	5	6	2	13
Total	12	18	6	36

devo encontrar os valores E_{ij} . Assim:

$$\begin{aligned}
 E_{11} &= \frac{11 \times 12}{36} \approx 3,67 & E_{21} &= \frac{12 \times 12}{36} = 4 & E_{31} &= \frac{13 \times 12}{36} \approx 4,3 \\
 E_{12} &= \frac{11 \times 18}{36} = 5,5 & E_{22} &= \frac{12 \times 18}{36} = 6 & E_{32} &= \frac{13 \times 18}{36} = 6,5 \\
 E_{13} &= \frac{11 \times 6}{36} \approx 1,83 & E_{23} &= \frac{12 \times 6}{36} = 2 & E_{33} &= \frac{13 \times 6}{36} \approx 2,16
 \end{aligned}$$

Teste Chi Quadrado

Finalmente, vamos calcular χ^2 (Chi - quadrado) através da expressão:

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

Assim,

$$\chi^2 = \frac{(4 - 3,67)^2}{3,67} + \dots + \frac{(2 - 2,16)^2}{2,16} \approx 0.663$$

Teste Qui- Quadrado

Por último, devemos encontrar o grau de liberdade.

Para encontrar o grau de liberdade devemos fazer :

$$gl = (\text{número de linha} - 1) \times (\text{número de coluna} - 1)$$

Assim, no exercício temos: 3 linhas e 3 colunas.

Logo $(3-1) \times (3-1) = 4$ graus de liberdade.

Utilizando a tabela e nível de significância 0.05 obtemos o valor de 9.448.

Teste Qui - Quadrado

Finalizando, como $0.663 < 9.448$ não rejeita H_0 .
Ou seja, o nível de ensino independe da região desta amostra.

Teste Qui - quadrado em Python :

<https://colab.research.google.com/drive/1xV0Xb-63C80lf1VU41mhsMFkzqC9nYiv>

Exemplo de Qui - Quadrado em TI

Um equipe de infraestrutura quer saber se certas vulnerabilidades são "exclusivas" de um sistema ou se os ataques ocorrem de forma aleatória, independentemente do OS.

1. As Variáveis (Qualitativas)

- **Variável X (Sistema Operativo):** Linux, Windows.
- **Variável Y (Tipo de Ataque):** Brute Force, SQL Injection, DDoS.

Exemplo

foi coletado os dados e criou a seguinte tabela

Tipo de Ataque / OS	Linux	Windows	Total
Brute Force	70	30	100
SQL Injection	20	80	100
DDoS	50	50	100
Total	140	160	300

Exemplo

H0 (Independência): O tipo de ataque **não depende** do Sistema Operativo. (Os hackers atacam qualquer um da mesma forma).

H1(Dependência): O tipo de ataque **está associado** ao Sistema Operativo. (Ex: certas fraquezas do Windows atraem mais SQL Injection).

Exemplo em Python.

https://colab.research.google.com/drive/1KoVLNP2UO0hfqsEonVrO_TeR1wepORE5