



Inferência Estatística

Aula 05– Estimadores e estimação

Prof. MSc. Kyung Moo Kim
EMAIL_DO_PROFESSOR
kyung.kim@faculdadeimpacta.com.br

Sumário

- Motivação
- Estimadores
- Estimador pontual
- Estimador por intervalo - Intervalo de confiança

Motivação

Exemplo: tempo de resposta (latência) de um servidor.

Quero saber o tempo médio de resposta de um servidor que recebe milhões de requisições por dia. É impossível medir todas, então usamos a inferência.

O que é inferência? é o processo de tirar conclusões sobre um grupo grande (população) a partir de um grupo pequeno (amostra).

Exemplo : Resultado de eleições. Amostra : 2000 pessoas.

População: 183 milhões.

Definição de estimador

um **estimador** é uma regra, fórmula ou algoritmo matemático aplicado aos dados de uma **amostra** com o objetivo de aproximar ou estimar um parâmetro desconhecido de uma **população** inteira.

Parâmetro (Θ): É uma característica numérica real e fixa da população que geralmente é desconhecida (ex: a média real de latência de todos os servidores da empresa, denotada por μ).

Estimador (theta chapeu): É a **função matemática ou regra** usada para calcular uma aproximação do parâmetro usando dados amostrais (ex: a fórmula da média amostral).

Estimativa: É o **valor numérico específico** obtido quando aplicamos o estimador aos dados coletados (ex: dizer que a média amostral calculada foi de 52.4 ms).

Estimadores

Em infêrencia estatística temos dois estimadores:

Estimador pontual : é uma regra ou fórmula que utiliza os dados de uma amostra para calcular um **único valor numérico** (um "ponto") que serve como o melhor palpite para um parâmetro populacional desconhecido.

Média Amostral $\bar{X}$:

- **O que estima:** A média da população μ
- **Uso em TI:** Estimar o tempo médio de carregamento de uma página com base em 1.000 acessos.

Proporção Amostral $\hat{p}$:

- **O que estima:** A proporção real de sucesso na população (p).
 - **Uso em TI:** Estimar a taxa de conversão (cliques) de um anúncio.
- $$\hat{p} = \frac{\text{número de itens com a característica na amostra}}{n}$$

Estimadores

Variância Amostral (S^2):

- **O que estima:** A dispersão ou instabilidade dos dados na população (σ^2).
- **Uso em TI:** Medir a oscilação (jitter) de uma conexão de rede

Exemplo

O Cenário: Estimar o consumo de memória de um Microserviço

Você gerencia um cluster de servidores e acabou de subir uma nova versão de um microserviço e precisa decidir quanta memória RAM deve reservar para cada instância desse serviço (o *limit* do container), mas você só tem dados de uma pequena amostra de tempo.

Exemplo

1. Coleta de Dados (A Amostra)

Você monitorou **5 instâncias** aleatórias do serviço e anotou o pico de uso de memória em MB:

- $X_1 = 150$ MB
- $X_2 = 175$ MB
- $X_3 = 160$ MB
- $X_4 = 190$ MB
- $X_5 = 155$ MB

Exemplo

2. Escolha dos Estimadores Pontuais

Queremos estimar dois parâmetros da população (o comportamento de *todas* as instâncias que rodarão no futuro):

1. **A Média (μ):** Para saber o consumo esperado.
2. **A Variância (σ^2):** Para entender o quão instável esse serviço é.

Os cálculos

Para estimar a média populacional, utilizamos a média amostral de 5 amostra.

$$\bar{x} = \frac{\sum_{i=1}^n X_i}{n}$$

Assim,

$$\bar{x} = \frac{150+175+160+190+155}{5} = \frac{830}{5} = 166 \text{ MB}$$

Os cálculos

O cálculo da variância deve ser realizada através de variância populacional (S^2).

$$s^2 = \frac{\sum (X_i - \bar{x})^2}{n-1}$$

Assim, calculando temos

Cálculos

X_i	$x_i - \text{media}$	$(x_i - \text{media})^2$
150	$150 - 166 = -16$	256
175	$175 - 166 = 9$	81
160	$160 - 166 = -6$	36
190	$190 - 166 = 24$	576
155	$155 - 166 = -11$	121

$$\sigma^2 = 1070/4 = 267.5$$

Conclusão

O consumo **médio** esperado é de **166 MB**.
"Como o desvio padrão (raiz da variância) é de aproximadamente **16,3 MB** ($\sqrt{267,5}$), o serviço é relativamente estável, mas precisamos de uma margem de segurança."

Intervalo de confiança

O que é? O **Intervalo de Confiança (IC)** é uma técnica da inferência estatística que, em vez de fornecer um único número (como o estimador pontual), fornece uma **faixa de valores prováveis** para um parâmetro desconhecido, acompanhada de um **nível de certeza**.

Intervalo de confiança

O intervalo de confiança é com média populacional μ e variância conhecida σ^2 com tamanho n segue a distribuição normal com a mesma média populacional μ e variância σ^2/n .

Assim,

$$Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$$

e fixando o valor de γ chegamos a expressão:

Intervalo de confiança

Para parâmetro μ :

$$IC(\mu, \gamma) = [\bar{X} - z_{\gamma/2} \cdot \frac{\sigma}{\sqrt{n}}; \bar{X} + z_{\gamma/2} \cdot \frac{\sigma}{\sqrt{n}}]$$

Para parâmetro p (proporção) - otimista:

$$IC(p, \gamma) = [\hat{p} - z_{\gamma/2} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}; \hat{p} + z_{\gamma/2} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}]$$

Para parâmetro p - conservativo.

$$IC(p, \gamma) = [\hat{p} - z_{\gamma/2} \cdot \sqrt{\frac{1}{4n}}; \hat{p} + z_{\gamma/2} \cdot \sqrt{\frac{1}{4n}}]$$

Exemplo

Suponhamos que que você é responsável por um e-commerce. Você precisa reportar a latência média (tempo de resposta) de uma API de checkout. Você coletou uma amostra de **100 requisições** ($n = 100$) para estimar a média real de **todas** as requisições do dia (μ).

Dados Coletados (Estimadores Pontuais)

- **Média Amostral** : 150 { ms} (Seu "melhor palpite").
- **Desvio Padrão Amostral**: \$20 \text{ ms}\$ (Quanto o tempo varia).
- **Tamanho da Amostra (n)**: 100
- **Nível de Confiança desejado**: 95% (o que nos dá um valor crítico $z = 1,96$).

Resolução

O erro padrão da média é calculado por $\frac{s}{\sqrt{n}}$. Aplicando na fórmula:

$$IC = 150 \pm 1,96 \cdot \left(\frac{20}{\sqrt{100}} \right)$$

$$IC = 150 \pm 1,96 \cdot (2)$$

$$IC = 150 \pm 3,92$$

Interpretação

"Temos **95% de confiança** de que a média real de latência de todas as requisições da nossa API está entre **146,08 ms** e **153,92 ms**."

- **Decisão Técnica:** Se o seu **SLA** (acordo de nível de serviço) exige que a latência média seja inferior a **160 ms**, você pode afirmar com segurança estatística que o sistema está operando dentro do contrato.
- **Por que não usar apenas a média (150ms)?** Porque se você tivesse pego outras 100 requisições, a média poderia ser 152ms ou 148ms. O intervalo de confiança mostra que, apesar dessa variação, você está "seguro" dentro daquela faixa.

Exemplo de IC com valor de p

Considere a seguinte situação: Você está monitorando 10 mil requisições ($n = 10.000$) e destas falharam 15. Nesse contexto apresentamos:

$$\hat{p} = \frac{15}{10000} = 0.15\%$$

Consideramos que o erro contratual for 0.1%. Verificamos que $0.15 > 0.1$. A questão é? o sistema deve ser desligado?

Para responder encontramos o IC com um 95%. Assim temos: $[0.0009; 0.0021]$. Isto é: a taxa de erro está entre: 0.09% e 0.12%. é do tipo conservador.

Com isto podemos concluir que não precisa desligar.

Intervalo de confinação em Python

<https://colab.research.google.com/drive/1wrY7yaHUMWpdgAkQuRDChduDQYLP7dcX?authuser=0>